



Instituto Tecnológico y de Estudios Superiores de Monterrey
Campus Estado de México, Escuela de Ingeniería y Ciencias.

Unidad de formación:

TC3009C.601

Inteligencia artificial avanzada para la ciencia de datos.

Momento de Retroalimentación: Módulo 2 Análisis y Reporte sobre el desempeño del modelo.

Aarón Ramírez Pulido

A01749666

16 de septiembre de 2026

Profesor: Jorge Adolfo Ramírez Uresti

Repositorio: <https://github.com/apachai-aaron/analisis-y-desempe-o-del-modelo>

1. Resumen

En esta actividad se analizó el desempeño del modelo Random Forest desarrollado previamente con scikit-learn sobre el Digits Dataset. El análisis se enfocó en comparar el comportamiento del modelo en los conjuntos de training, validation y test, diagnosticar su grado de bias y varianza, identificar situaciones de underfitting, ajuste adecuado y tendencia al overfitting, y aplicar una técnica de regularización mediante el hiperparámetro `max_depth`.

Se compararon cuatro niveles de complejidad (`max_depth = 2, 5, 10` y `None`). Los resultados mostraron que una profundidad de 2 produce underfitting, mientras que una profundidad de 10 ofrece el mejor equilibrio entre capacidad de aprendizaje y generalización. El modelo sin límite de profundidad mantiene un ajuste perfecto sobre training, pero no mejora validation, por lo que se identifica una ligera tendencia al overfitting. La regularización mediante `max_depth = 10` incrementó el Validation Macro F1 de 0.9662 a 0.9702 y redujo el gap Train-Validation de 0.0338 a 0.0298. Diagnóstico final: el modelo seleccionado (`max_depth = 10`) presenta bias bajo, varianza baja-media y un nivel de ajuste adecuado.

Resultado principal

La configuración seleccionada fue Random Forest con 100 árboles y `max_depth = 10`. El modelo final alcanzó Accuracy = 97.78% y Macro F1-score = 0.9778 sobre el test set.

2. Modelo y conjunto de datos

2.1 Modelo analizado

Se seleccionó la implementación con framework realizada previamente: un Random Forest Classifier de scikit-learn. Random Forest combina múltiples Decision Trees entrenados con muestras bootstrap y subconjuntos aleatorios de features, y posteriormente agrega sus predicciones. Esta estrategia reduce la dependencia de un único árbol y ayuda a controlar la varianza.

2.2 Digits Dataset

El Digits Dataset de Scikit-learn contiene 1,797 observaciones. Cada observación representa una imagen de 8 x 8 píxeles de un dígito escrito a mano, por lo que existen 64 features numéricos. La variable objetivo contiene 10 clases: los dígitos del 0 al 9.

Característica	Valor
Observaciones	1,797
Features	64
Clases	10 (0-9)
Tipo de problema	Clasificación multiclase

Algoritmo	Random Forest Classifier
Framework	Scikit-learn

2.2 División Train / Validation / Test

Los datos se dividieron mediante `train_test_split()` con `random_state = 42` y `stratify`, con el propósito de conservar aproximadamente la proporción de cada clase en los tres subconjuntos.

Conjunto	Observaciones	Uso
Training	1,257 ($\approx 70\%$)	Ajuste de los modelos
Validation	270 ($\approx 15\%$)	Selección de hiperparámetros y diagnóstico
Test	270 ($\approx 15\%$)	Evaluación final / evidencia de generalización

El conjunto de test no se utilizó para seleccionar hiperparámetros. La elección de la configuración se realizó con validation para evitar ajustar el modelo específicamente al conjunto de prueba.

3. Indicadores y criterio de evaluación

La métrica principal utilizada fue Macro F1-score, debido a que el problema contiene diez clases y se busca evaluar de forma equilibrada el desempeño en todas ellas. Macro F1 calcula el F1-score de cada clase y después obtiene el promedio otorgando el mismo peso a cada clase.

Accuracy se utilizó como indicador complementario. Además, para apoyar el diagnóstico de varianza se calculó el gap de generalización:

$$\text{Gap F1} = \text{Train Macro F1} - \text{Validation Macro F1}$$

Una brecha mayor puede ser señal de mayor sensibilidad a los datos de entrenamiento. Sin embargo, este gap se usa aquí como indicador diagnóstico y no como una descomposición matemática exacta de bias y varianza.

4. Experimento de complejidad del modelo

Para analizar cómo cambia el desempeño al aumentar la capacidad del modelo, se mantuvo fijo `n_estimators = 100` y se modificó únicamente `max_depth`. Esto permite atribuir las diferencias observadas principalmente al nivel de complejidad de los árboles.

4.1 Configuración controlada del experimento

Para que la comparación de complejidad fuera interpretable, se mantuvieron fijos los demás hiperparámetros y se modificó únicamente `max_depth`. Así, los cambios en el desempeño pueden asociarse principalmente con la profundidad de los árboles.

Hiperparámetro		Valor	Función en el experimento	
n_estimators		100	Mantiene constante el número de árboles.	
criterion		gini	Criterio de división de cada Decision Tree.	
min_samples_split		2	Mínimo para intentar dividir un nodo.	
min_samples_leaf		1	Mínimo permitido en una hoja.	
max_features		sqrt	Introduce diversidad entre árboles.	
bootstrap		True	Entrena cada árbol con muestreo con reemplazo.	
random_state		42	Hace reproducibles los resultados.	
max_depth		2, 5, 10, None	Único hiperparámetro variado para estudiar complejidad.	
Configuración		Train Acc	Val Acc	Test Acc
max_depth = 2		0.8433	0.8222	0.8111
max_depth = 5		0.9722	0.9222	0.9370
max_depth = 10		1.0000	0.9704	0.9630
max_depth = None		1.0000	0.9667	0.9667

Configuración	Train Macro F1	Val Macro F1	Test Macro F1	Gap F1
max_depth = 2	0.8407	0.8089	0.8057	0.0318
max_depth = 5	0.9721	0.9219	0.9373	0.0502
max_depth = 10	1.0000	0.9702	0.9626	0.0298
max_depth = None	1.0000	0.9662	0.9664	0.0338




Figura 1. Macro F1-score en training, validation y test conforme aumenta la complejidad del modelo.




Figura 2. Accuracy en training, validation y test para los distintos valores de max_depth.

5. Diagnóstico del bias o sesgo

El bias se diagnosticó de forma cualitativa observando el rendimiento del modelo incluso sobre el training. Cuando un modelo obtiene un desempeño bajo en training, su capacidad es insuficiente para capturar los patrones relevantes, lo que indica bias alto.

Configuración	Diagnóstico de bias	Justificación
max_depth = 2	Alto	Train F1 = 0.8407; el modelo no ajusta bien a los datos de entrenamiento.
max_depth = 5	Medio-bajo	Train F1 = 0.9721; aprende bien, aunque con menor capacidad que depth 10.
max_depth = 10	Bajo	Train F1 = 1.0000 y el mejor Validation F1 = 0.9702.
max_depth = None	Bajo	Train F1 = 1.0000; capacidad suficiente para memorizar training.

El caso más claro de bias alto es max_depth = 2. La reducción simultánea en training, validation y test muestra que el modelo es demasiado simple; no se trata de un problema de generalización, sino de falta de capacidad.

6. Diagnóstico de la varianza

La varianza se diagnosticó principalmente mediante la brecha Train-Validation y el comportamiento de validation al incrementar la complejidad. En Random Forest, la agregación de múltiples árboles ya reduce la varianza respecto a un Decision Tree individual, por lo que no se espera un crecimiento extremo de la brecha.

Configuración	Gap F1	Diagnóstico de varianza	Interpretación
max_depth = 2	0.0318	Baja	Modelo simple; bajo desempeño en ambos conjuntos.

max_depth = 5	0.0502	Media	Mayor brecha Train-Validation de las configuraciones evaluadas.
max_depth = 10	0.0298	Baja-media	Menor brecha entre los modelos de alta capacidad.
max_depth = None	0.0338	Media	Más complejidad sin mejora en validation; ligera tendencia a variar más.

Diagnóstico importante

No se afirma que max_depth=None tenga overfitting severo. El comportamiento observado corresponde a una tendencia leve: training permanece perfecto, pero validation deja de mejorar al aumentar la complejidad.

7. Nivel de ajuste: underfit, fit y overfit

Configuración	Nivel de ajuste	Evidencia
max_depth = 2	Underfit	Train/Val/Test F1 $\approx$ 0.84/0.81/0.81; capacidad claramente insuficiente.
max_depth = 5	Intermedio / subóptimo	Mejora fuerte, pero Val F1 = 0.9219 queda por debajo del óptimo.
max_depth = 10	Fit adecuado	Máximo Val F1 = 0.9702 y gap controlado = 0.0298.
max_depth = None	Overfit leve / tendencia	Training perfecto, pero Val F1 baja a 0.9662.

El comportamiento completo puede observarse en las Figuras 1 y 2. Con profundidad 2, las tres curvas permanecen bajas, lo cual es característico de underfitting. Al aumentar la profundidad, el modelo aprende mejor y alcanza su mejor desempeño de validation en profundidad 10. Al eliminar el límite, training se mantiene perfecto pero validation disminuye ligeramente, por lo que el incremento de complejidad deja de aportar generalización.

8. Regularización y mejora del modelo

La técnica de regularización aplicada fue limitar la profundidad máxima de los árboles mediante max_depth. Se comparó el modelo sin límite explícito (max_depth=None) contra el modelo regularizado (max_depth=10).

Indicador	Sin límite	max_depth = 10	Cambio
Train Macro F1	1.0000	1.0000	Sin cambio
Validation Macro F1	0.9662	0.9702	+0.0040
Gap Train-Val F1	0.0338	0.0298	-0.0040

Aclaración sobre los resultados de test: en la tabla comparativa de complejidad, el modelo max_depth=10 obtiene Test Macro F1 = 0.9626 porque cada configuración fue entrenada únicamente con el training set para mantener una comparación homogénea. Después de elegir los hiperparámetros con validation, el modelo final se reentrenó con training + validation (1,527 observaciones), por lo que su Test Macro F1 final aumenta a 0.9778. Esta diferencia no implica uso del test para seleccionar hiperparámetros.

La regularización mejoró el Validation Macro F1 en 0.0040, equivalente a 0.40 puntos porcentuales, y redujo el gap Train-Validation en la misma magnitud. Aunque la mejora numérica es pequeña, es consistente: se obtiene un modelo menos complejo, con mejor desempeño en validation y menor brecha respecto a training.




Figura 3. Comparación antes y después de limitar max_depth. La regularización mejora validation sin reducir training.

Es importante notar que el test set no se utilizó para decidir esta regularización. La selección de max_depth=10 se justificó con validation. El hecho de que el modelo sin límite obtenga un Test F1 ligeramente mayor en la comparación experimental no cambia la selección, ya que elegir hiperparámetros con test produciría sesgo de evaluación.

9. Evaluación del modelo final seleccionado

Después de seleccionar n_estimators = 100 y max_depth = 10 con el conjunto de validation, el modelo final se reentrenó usando training + validation (1,527 observaciones) y se evaluó una sola vez sobre las 270 observaciones del test set.

Métrica final	Resultado
Accuracy	0.9778 (97.78%)
Macro Precision	0.9785
Macro Recall	0.9776
Macro F1-score	0.9778
Predicciones correctas	264 de 270




Figura 4. Matriz de confusión del modelo final en el test set.

La matriz de confusión muestra que la mayoría de los valores se concentran en la diagonal principal. Los seis errores fueron: 0→4 (1 caso), 3→9 (1), 6→8 (1), 8→1 (2) y 9→3 (1). Los dígitos 2, 5 y 7 se clasificaron correctamente en todos los casos del test.

10. Consideraciones y limitaciones

- El diagnóstico de bias y varianza es cualitativo y se apoya en curvas de desempeño, gaps de generalización y complejidad del modelo; no corresponde a una descomposición estadística exacta del error.
- Random Forest ya incorpora mecanismos que reducen la varianza (bootstrap, selección aleatoria de features y agregación de múltiples árboles), por lo que el overfitting observado al aumentar la profundidad es leve.
- El test set se mantuvo fuera del proceso de selección de hiperparámetros. Esto permite usarlo como evidencia más confiable de generalización.
- La métrica principal fue Macro F1 para dar el mismo peso a las diez clases; Accuracy se reportó como métrica complementaria.

Repositorio del proyecto: <https://github.com/apachai-aaron/analisis-y-desempe-o-del-modelo>

11. Conclusiones

El análisis permitió identificar de forma clara cómo la complejidad de Random Forest afecta su desempeño. Con `max_depth=2`, el modelo presenta bias alto y underfitting, ya que no alcanza un buen ajuste ni siquiera sobre training. Con `max_depth=10`, el modelo presenta bias bajo, varianza controlada y el mejor desempeño en validation, por lo que se considera el nivel de ajuste adecuado. Al eliminar el límite de profundidad, la complejidad adicional no mejora validation y aparece una ligera tendencia al overfitting.

La regularización mediante `max_depth=10` mejoró la Validation Macro F1 de 0.9662 a 0.9702 y redujo el gap Train-Validation de 0.0338 a 0.0298. El modelo final, reentrenado con training + validation, alcanzó un Accuracy de 97.78% y un Macro F1-score de 0.9778 en test. En conjunto, los resultados respaldan que la configuración seleccionada logra un equilibrio adecuado entre capacidad de aprendizaje y generalización.

10. Referencias

Scikit-learn.	RandomForestClassifier	-	documentación	oficial.
https://scikit-learn.org/stable/modules/generated/sklearn.ensemble.RandomForestClassifier.html				
Scikit-learn.	Digits	Dataset	(load_digits)	- documentación oficial.
https://scikit-learn.org/stable/modules/generated/sklearn.datasets.load_digits.html				
Scikit-learn.	train_test_split	-	documentación	oficial.
https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.train_test_split.html				
Scikit-learn.	Métricas de evaluación y clasificación	-	documentación	oficial.
https://scikit-learn.org/stable/modules/model_evaluation.html				